



НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ
УНИВЕРСИТЕТ

Morphological disambiguation

Francis M. Tyers

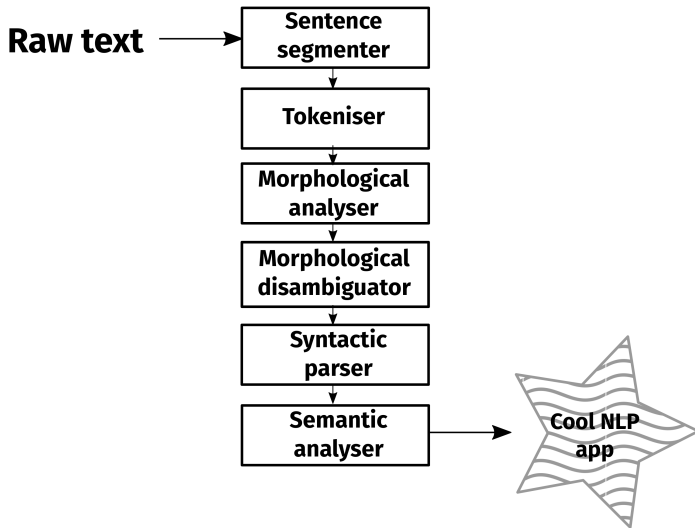
ftyers@hse.ru

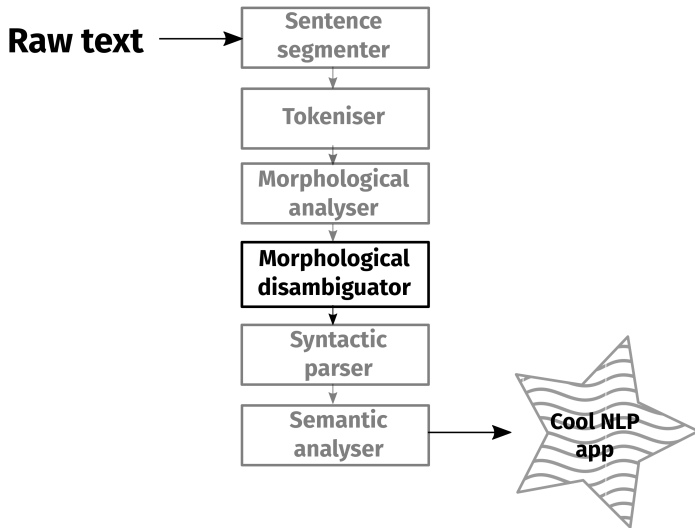
<https://www.hse.ru/org/persons/209454856>

Национальный исследовательский университет
«Высшая школа экономики» (Москва)

4 марта 2018 г.







- **Speech synthesis:** How to pronounce a word in context, e.g.
- **Disambiguation of meaning:**
- **Features for parsing:**

Part-of-speech tagging:

- Traditional term, based on approach(es) for English, finite-set of tags for all combinations of lexical category and morphology.

In:	This	is	a	test
	This/PRON	is/VERB	a/DET	test/NOUN

Morphological disambiguation:

- More cross-linguistically applicable, conception is of disambiguating after morphological analysis.

In:	This/DET/PRON	is/VERB	a/DET	test/VERB/NOUN
	This/PRON	is/VERB	a/DET	test/NOUN

What is a tagset?



Penn Treebank

This/DT
tagset/NNS
contains/VBZ
48/CD
unique/JJ
tags/NNP
./.

- 48 tags
- Tags are atomic
- Principles have been applied to other languages (Chinese, Bengali, ...)
- Extensible ?

Table 2
The Penn Treebank POS tagset.

1. CC	Coordinating conjunction	25. TO	<i>to</i>
2. CD	Cardinal number	26. UH	Interjection
3. DT	Determiner	27. VB	Verb, base form
4. EX	Existential <i>there</i>	28. VBD	Verb, past tense
5. FW	Foreign word	29. VBG	Verb, gerund/present participle
6. IN	Preposition/subordinating conjunction	30. VBN	Verb, past participle
7. JJ	Adjective	31. VBP	Verb, non-3rd ps. sing. present
8. JJR	Adjective, comparative	32. VBZ	Verb, 3rd ps. sing. present
9. JJS	Adjective, superlative	33. WDT	<i>wh</i> -determiner
10. LS	List item marker	34. WP	<i>wh</i> -pronoun
11. MD	Modal	35. WP\$	Possessive <i>wh</i> -pronoun
12. NN	Noun, singular or mass	36. WRB	<i>wh</i> -adverb
13. NNS	Noun, plural	37. #	Pound sign
14. NNP	Proper noun, singular	38. \$	Dollar sign
15. NNPS	Proper noun, plural	39. .	Sentence-final punctuation
16. PDT	Predeterminer	40. ,	Comma
17. POS	Possessive ending	41. :	Colon, semi-colon
18. PRP	Personal pronoun	42. (Left bracket character
19. PP\$	Possessive pronoun	43.)	Right bracket character
20. RB	Adverb	44. "	Straight double quote
21. RBR	Adverb, comparative	45. '	Left open single quote
22. RBS	Adverb, superlative	46. "	Left open double quote
23. RP	Particle	47. '	Right close single quote
24. SYM	Symbol (mathematical or scientific)	48. "	Right close double quote

Positional tags

Mnemonic tags

Feature/value pairs

1	Польша	—	PROPN	—	Animacy=Inan Case=Nom Gender=Fem Number=Sing	—	—	—
2	является	—	VERB	—	Aspect=Imp Number=Sing Person=3 Tense=Pres	—	—	—
3	безъядерной	—	ADJ	—	Animacy=Inan Case=Ins Gender=Fem Number=Sing	—	—	—
4	страной	—	NOUN	—	Animacy=Inan Case=Ins Gender=Fem Number=Sing	—	—	—
5	.	—	PUNCT	—	—	—	—	—

- +/-



They finished catching reindeer.

Њорагыркиплыткогъат Њора-гырки-плыткогъат
reindeer-catch-finish-pl3



- Intraparadigmatic
- Morphosyntactically incongruent
- Morphosyntactically congruent

- **Rule-based:**
- **HMM-based:**
- **Averaged perceptron:**

Rule-based

- Developed by Fred Karlsson¹ in the late 1980s
- Does not aim at producing a full “parse tree”
- Describes what is *ungrammatical*, not what is grammatical
- Linguists formalise “constraints” which describe language impossibilities
 - e.g. “No noun can be in prepositional case without a preposition which governs the prepositional case.”
- No “encapsulation”, all parts of the analysis (surface form → semantics) are always available
- Input is all possible analyses, output is only possible analyses

¹The same Fred Karlsson that wrote “Finsk grammatik”.

Input:

```
«Польша»
  "Польша"np top f sg nom
«является»
  "являться"v impf iv pres p3 sg
«безъядерной»
  "безъядерный"adj f an sg gen
  "безъядерный"adj f an sg dat
  "безъядерный"adj f an sg prp
  "безъядерный"adj f an sg ins
«страной»
  "страна"n f nn sg ins
«.»
  "."sent
```

Operators:

- select: Discard all readings except the reading matching a condition
- remove: Discard a single reading matching a condition

Context conditions:

- (-1 pres) → previous token has the tag `PRES`
- (1C ins) → following token *only* has the tag `INS`
- (NOT -1* pr) → no token to the left has the tag `PR`

Input:

```
«Польша>”
  ”Польша”np top f sg nom
«является>”
  ”являться”v impf iv pres p3 sg
«безъядерной>”
  ”безъядерный”adj f an sg gen
  ”безъядерный”adj f an sg dat
  ”безъядерный”adj f an sg prp
  ”безъядерный”adj f an sg ins
«страной>”
  ”страна”n f nn sg ins
«. >”
  ”.”sent
```

Input:

```
«Польша>”
  ”Польша”np top f sg nom
«является>”
  ”являться”v impf iv pres p3 sg
«безъядерной>”
  ”безъядерный”adj f an sg gen
  ”безъядерный”adj f an sg dat
  ”безъядерный”adj f an sg prp
  ”безъядерный”adj f an sg ins
«страной>”
  ”страна”n f nn sg ins
«. >”
  ”.”sent
```

1 REMOVE prp IF (not -1* pr)

Input:

«Польша»
"Польша"np top f sg nom
«является»
"является"v impf iv pres p3 sg
«безъядерной»
"безъядерный"adj f an sg gen
"безъядерный"adj f an sg dat
"безъядерный"adj f an sg prp
"безъядерный"adj f an sg ins
«страной»
"страна"n f nn sg ins
«.»
"."sent

- 1 REMOVE prp IF (not -1* pr)
- 2 REMOVE gen IF (-1 pres)
(0C adj) (not 1 gen)

Input:

```
«Польша>”  
  ”Польша”np top f sg nom  
«является»”  
  ”являться”v impf iv pres p3 sg  
«безъядерной»”  
  ”безъядерный”adj f an sg gen  
  ”безъядерный”adj f an sg dat  
  ”безъядерный”adj f an sg prp  
  ”безъядерный”adj f an sg ins  
«страной»”  
  ”страна”n f nn sg ins  
«.>”  
  ”.”sent
```

- 1 REMOVE prp IF (not -1* pr)
- 2 REMOVE gen IF (-1 pres)
(0C adj) (not 1 gen)

Exercise: Can we safely remove the dative reading?

« Для соседних с Руандой государств руандийские события апреля – июля 1994 года вылились в огромное число прибывших беженцев . »

Для	PR
соседних	A=pl,gen,plen
с	PR
Руандой	S,f,inan=sg,ins
государств	S,n,inan=pl,gen
руандийские	A=pl,acc,inan,plen
события	S,n,inan=pl,acc
апреля	S,m,inan=sg,gen
–	–
июля	S,m,inan=sg,gen
1994	NUM=ciph
года	S,m,inan=sg,gen
вылились	V,pf,intr,med=pl,praet,indic
в	PR
огромное	A=n,sg,acc,inan,plen
число	S,n,inan=sg,acc
прибывших	V,pf,intr,act=partcp,pl,gen,praet,plen
беженцев	S,m,anim=pl,gen
.	.

Для	PR
соседних	A=pl,gen,plen
с	PR
Руандой	S,f,inan=sg,ins
государств	S,n,inan=pl,gen
руандийские	A=pl,acc,inan,plen
события	S,n,inan=pl,acc
апреля	S,m,inan=sg,gen
–	–
июля	S,m,inan=sg,gen
1994	NUM=ciph
года	S,m,inan=sg,gen
вылились	V,pf,intr,med=pl,praet,indic
в	PR
огромное	A=n,sg,acc,inan,plen
число	S,n,inan=sg,acc
прибывших	V,pf,intr,act=partcp,pl,gen,praet,plen
беженцев	S,m,anim=pl,gen
.	.

2 / 19 = 89.5% accuracy

«Для>”
 "для"pr
«соседних>”
 "соседний"adj mfn an pl gen
 "соседний"adj mfn an pl prp
 "соседний"adj mfn aa pl acc
«с>”
 "с"pr
«Руандой>”
 "Руанда"np top f sg ins
«государств>”
 "государство"n nt nn pl gen
«руандийские>”
 "руандийский"adj mfn an pl nom
 "руандийский"adj mfn nn pl acc
«события>”
 "событие"n nt nn sg gen
 "событие"n nt nn pl nom
 "событие"n nt nn pl acc
«апреля>”
 "апрель"n m nn sg gen
«->”
 "-“guio
«июля>”
 "июль"n m nn sg gen

«1994>”
 "1994"num
«года>”
 "год"n m nn sg gen
«вылились>”
 "вылиться"v perf iv past mfn pl
«в>”
 "в"pr
«огромное>”
 "огромный"adj nt an sg nom
 "огромный"adj nt an sg acc
«число>”
 "число"n nt nn sg acc
 "число"n nt nn sg nom
«прибывших>”
 "прибыть"v perf iv pp actv mfn an pl acc
 "прибыть"v perf iv pp actv mfn an pl prp
 "прибыть"v perf iv pp actv mfn aa pl gen
«беженцев>”
 "беженец"n m aa pl gen
 "беженец"n m aa pl acc
«. >”
 "."sent

rule: -

«Для»

"для"pr

«соседних»

"соседний"adj mfn an pl gen

"соседний"adj mfn an pl prp

"соседний"adj mfn aa pl acc

«с»

"с"pr

«Руандой»

"Руанда"np top f sg ins

«государств»

"государство"n nt nn pl gen

«руандийские»

"руандийский"adj mfn an pl nom

"руандийский"adj mfn nn pl acc

«события»

"событие"n nt nn sg gen

"событие"n nt nn pl nom

"событие"n nt nn pl acc

«апреля»

"апрель"n m nn sg gen

«-»

"-"guio

«июля»

"июль"n m nn sg gen

«1994»

"1994"num

«года»

"год"n m nn sg gen

«вылились»

"вылиться"v perf iv past mfn pl

«в»

"в"pr

«огромное»

"огромный"adj nt an sg nom

"огромный"adj nt an sg acc

«число»

"число"n nt nn sg acc

"число"n nt nn sg nom

«прибывших»

"прибыть"v perf iv pp actv mfn an pl acc

"прибыть"v perf iv pp actv mfn an pl prp

"прибыть"v perf iv pp actv mfn aa pl gen

«беженцев»

"беженец"n m aa pl gen

"беженец"n m aa pl acc

«.»

". "sent

rule: 1

«Для>”
 "для"pr
«соседних>”
 "соседний"adj mfn an pl gen
 "соседний"adj mfn an pl prp
 "соседний"adj mfn aa pl acc
«с>”
 "с"pr
«Руандой>”
 "Руанда"np top f sg ins
«государств>”
 "государство"n nt nn pl gen
«руандийские>”
 "руандийский"adj mfn an pl nom
 "руандийский"adj mfn nn pl acc
«события>”
 "событие"n nt nn sg gen
 "событие"n nt nn pl nom
 "событие"n nt nn pl acc
«апреля>”
 "апрель"n m nn sg gen
«->”
 "-“guio
«июля>”
 "июль"n m nn sg gen

«1994>”
 "1994"num
«года>”
 "год"n m nn sg gen
«вылились>”
 "вылиться"v perf iv past mfn pl
«в>”
 "в"pr
«огромное>”
 "огромный"adj nt an sg nom
 "огромный"adj nt an sg acc
«число>”
 "число"n nt nn sg acc
 "число"n nt nn sg nom
«прибывших>”
 "прибыть"v perf iv pp actv mfn an pl acc
 "прибыть"v perf iv pp actv mfn an pl prp
 "прибыть"v perf iv pp actv mfn aa pl gen
«беженцев>”
 "беженец"n m aa pl gen
 "беженец"n m aa pl acc
«.>”
 "."sent

rule: 2

«Для»
"для"pr
«соседних»
"соседний"adj mfn an pl gen
"соседний"adj mfn an pl prp
"соседний"adj mfn aa pl acc
«с»
"с"pr
«Руандой»
"Руанда"np top f sg ins
«государств»
"государство"n nt nn pl gen
«руандийские»
"руандийский"adj mfn an pl nom
"руандийский"adj mfn nn pl acc
«события»
"событие"n nt nn sg gen
"событие"n nt nn pl nom
"событие"n nt nn pl acc
«апреля»
"апрель"n m nn sg gen
«-»
"- "guio
«июля»
"июль"n m nn sg gen

«1994»
"1994"num
«года»
"год"n m nn sg gen
«выпились»
"выпиться"v perf iv past mfn pl
«в»
"в"pr
«огромное»
"огромный"adj nt an sg nom
"огромный"adj nt an sg acc
«число»
"число"n nt nn sg acc
"число"n nt nn sg nom
«прибывших»
"прибыть"v perf iv pp actv mfn an pl acc
"прибыть"v perf iv pp actv mfn an pl prp
"прибыть"v perf iv pp actv mfn aa pl gen
«беженцев»
"беженец"n m aa pl gen
"беженец"n m aa pl acc
«.»
"."sent

rule: 3

«Для»
"для"pr
«соседних»
"соседний"adj mfn an pl gen
"соседний"adj mfn an pl prp
"соседний"adj mfn aa pl acc
«с»
"с"pr
«Руандой»
"Руанда"np top f sg ins
«государств»
"государство"n nt nn pl gen
«руандийские»
"руандийский"adj mfn an pl nom
"руандийский"adj mfn nn pl acc
«события»
"событие"n nt nn sg gen
"событие"n nt nn pl nom
"событие"n nt nn pl acc
«апреля»
"апрель"n m nn sg gen
«-»
"- "guio
«июля»
"июль"n m nn sg gen

«1994»
"1994"num
«года»
"год"n m nn sg gen
«выпились»
"выпить"v perf iv past mfn pl
«в»
"в"pr
«огромное»
"огромный"adj nt an sg nom
"огромный"adj nt an sg acc
«число»
"число"n nt nn sg acc
"число"n nt nn sg nom
«прибывших»
"прибыть"v perf iv pp actv mfn an pl acc
"прибыть"v perf iv pp actv mfn an pl prp
"прибыть"v perf iv pp actv mfn aa pl gen
«беженцев»
"беженец"n m aa pl gen
"беженец"n m aa pl acc
«.»
"."sent

rule: 4

«Для»
"для"pr
«соседних»
"соседний"adj mfn an pl gen
"соседний"adj mfn an pl prp
"соседний"adj mfn aa pl acc
«с»
"с"pr
«Руандой»
"Руанда"np top f sg ins
«государств»
"государство"n nt nn pl gen
«руандийские»
"руандийский"adj mfn an pl nom
"руандийский"adj mfn nn pl acc
«события»
"событие"n nt nn sg gen
"событие"n nt nn pl nom
"событие"n nt nn pl acc
«апреля»
"апрель"n m nn sg gen
«-»
"- "guio
«июля»
"июль"n m nn sg gen

«1994»
"1994"num
«года»
"год"n m nn sg gen
«вылились»
"вылиться"v perf iv past mfn pl
«в»
"в"pr
«огромное»
"огромный"adj nt an sg nom
"огромный"adj nt an sg acc
«число»
"число"n nt nn sg acc
"число"n nt nn sg nom
«прибывших»
"прибыть"v perf iv pp actv mfn an pl acc
"прибыть"v perf iv pp actv mfn an pl prp
"прибыть"v perf iv pp actv mfn aa pl gen
«беженцев»
"беженец"n m aa pl gen
"беженец"n m aa pl acc
«.»
"."sent

rule: 5

«Для»
"для"pr
«соседних»
"соседний"adj mfn an pl gen
"соседний"adj mfn an pl prp
"соседний"adj mfn aa pl acc
«с»
"с"pr
«Руандой»
"Руанда"np top f sg ins
«государств»
"государство"n nt nn pl gen
«руандийские»
"руандийский"adj mfn an pl nom
"руандийский"adj mfn nn pl acc
«события»
"событие"n nt nn sg gen
"событие"n nt nn pl nom
"событие"n nt nn pl acc
«апреля»
"апрель"n m nn sg gen
«-»
"- "guio
«июля»
"июль"n m nn sg gen

«1994»
"1994"num
«года»
"год"n m nn sg gen
«вылились»
"вылиться"v perf iv past mfn pl
«в»
"в"pr
«огромное»
"огромный"adj nt an sg nom
"огромный"adj nt an sg acc
«число»
"число"n nt nn sg acc
"число"n nt nn sg nom
«прибывших»
"прибыть"v perf iv pp actv mfn an pl acc
"прибыть"v perf iv pp actv mfn an pl prp
"прибыть"v perf iv pp actv mfn aa pl gen
«беженцев»
"беженец"n m aa pl gen
"беженец"n m aa pl acc
«.»
"."sent

rule: 5

- 1 Immediately after “для” remove any reading which is in a case other than genitive.

Exceptions:

- None ?

Formalised:

```
LIST Gen = gen ;  
SET NGDAIP = nom OR gen OR dat OR acc OR ins OR prp ;  
REMOVE NGDAIP - Gen IF (-1C (“для”)) ;
```

2 After "B" remove any reading which is in nominative

Exceptions:

- Joining an organisation ?

Formalised:

```
LIST Nom = nom ;  
REMOVE Nom IF (-1C ("B")) ;
```

- 3 In a sentence with a single intransitive finite verb, remove any reading in accusative which is not immediately governed by a preposition

Exceptions:

- There is a trans. part. form having an acc. arg.
- Some adverbial forms... *Мы проехали километр.*

Formalised:

LIST IV = iv ;

LIST TV = tv ;

LIST Acc = acc ;

LIST Pr = pr ;

REMOVE Acc IF (0 Acc LINK NOT -1* Pr) ((-1* IV) OR (1* IV)) (0 Acc LINK NOT 1* TV) (0 Acc LINK NOT -1* TV) ;

- 4 Select nominative if there is an intransitive verb which agrees with a nominative noun in the sentence for number (and/or gender)
- and is preceded by an adj. that can only be nom.
 - and there is no other nom. head in the sentence.

Exceptions:

- Appositions, titles, parentheticals ? Non-canonical agreement ?

Formalised:

```
LIST Head = np n prn ;  
SET NUM = (sg) OR (pl) ;  
SELECT Nom + $$NUM IF (-1C A + Nom) (NOT -1* Head + Nom)  
(NOT 1* Head + Nom) ((-1* V + $$NUM) OR (1* V + $$NUM)) ;
```

- 5 If there is a prepositional case reading, remove it if you see a noun which is only in a case other than prepositional without any preceding transitive participle form

Exceptions:

- ...

Formalised:

LIST Prp = prp ;

LIST N = n ;

REMOVE Prp IF $(-1 * N + \text{NGDAIP} - \text{Prp})$;

«Для>”
 "для"pr
«соседних>”
 "соседний"adj mfn an pl gen
 "соседний"adj mfn an pl prp
 "соседний"adj mfn aa pl acc
«с>”
 "с"pr
«Руандой>”
 "Руанда"np top f sg ins
«государств>”
 "государство"n nt nn pl gen
«руандийские>”
 "руандийский"adj mfn an pl nom
 "руандийский"adj mfn nn pl acc

«события>”
 "событие"n nt nn sg gen
 "событие"n nt nn pl nom
 "событие"n nt nn pl acc

«апреля>”
 "апрель"n m nn sg gen

«->”
 "- "guio

«июля>”
 "июль"n m nn sg gen

«1994>”
 "1994"num
«года>”
 "год"n m nn sg gen
«выпились>”
 "выпить"v perf iv past mfn pl
«в>”
 "в"pr
«огромное>”
 "огромный"adj nt an sg nom
 "огромный"adj nt an sg acc
«число>”
 "число"n nt nn sg acc
 "число"n nt nn sg nom

«прибывших>”
 "прибыть"v perf iv pp actv mfn an pl acc
 "прибыть"v perf iv pp actv mfn an pl prp
 "прибыть"v perf iv pp actv mfn aa pl gen
«беженцев>”

 "беженец"n m aa pl gen
 "беженец"n m aa pl acc

«.>”
 "."sent







Languages with constraint grammars:

- Finnish
- North Sámi, Lule Sámi, South Sámi
- Norwegian (Nynorsk, Bokmål)
- Faroese
- Udmurt
- Breton

HMM-based



Analysed:

Vino/NOUN/VERB a/ADP la/DET/PRON playa/NOUN ./PUNCT
Voy/VERB a/ADP la/DET/PRON casa/NOUN/VERB ./PUNCT
Bebe/VERB vino/NOUN/VERB en/ADP casa/NOUN/VERB ./PUNCT
La/DET/PRON casa/NOUN/VERB es/VERB grande/ADJ ./PUNCT
Es/VERB una/DET/PRON/VERB ciudad/NOUN grande/ADJ ./PUNCT

Tagged:

Vino/VERB a/ADP la/DET playa/NOUN ./PUNCT
Voy/VERB a/ADP la/DET casa/NOUN ./PUNCT
Bebe/VERB vino/NOUN en/ADP casa/NOUN ./PUNCT
La/DET casa/NOUN es/VERB grande/ADJ ./PUNCT
Es/VERB una/DET ciudad/NOUN grande/ADJ ./PUNCT

We calculate the transition probabilities, A from a matrix of transition counts:

	Second tag						
	VERB	NOUN	DET	PRON	ADP	ADJ	PUNCT
VERB	0	1	1	0	2	1	0
NOUN	1	0	0	0	1	1	3
DET	0	4	0	0	0	0	0
PRON	0	0	0	0	0	0	0
ADP	0	1	2	0	0	0	0
ADJ	0	0	0	0	0	0	2
PUNCT	3	0	1	0	0	0	0

We calculate the transition probabilities, A from a matrix of transition counts:

	Second tag						
	VERB	NOUN	DET	PRON	ADP	ADJ	PUNCT
VERB	0	1	1	0	2	1	0
NOUN	1	0	0	0	1	1	3
DET	0	4	0	0	0	0	0
PRON	0	0	0	0	0	0	0
ADP	0	1	2	0	0	0	0
ADJ	0	0	0	0	0	0	2
PUNCT	3	0	1	0	0	0	0

We calculate the transition probabilities, A from a matrix of transition counts:

	Second tag						
	VERB	NOUN	DET	PRON	ADP	ADJ	PUNCT
VERB	0	1	1	0	2	1	0
NOUN	1	0	0	0	1	1	3
DET	0	4	0	0	0	0	0
PRON	0	0	0	0	0	0	0
ADP	0	1	2	0	0	0	0
ADJ	0	0	0	0	0	0	2
PUNCT	3	0	1	0	0	0	0

We calculate the transition probabilities, A from a matrix of transition counts:

	Second tag						
	VERB	NOUN	DET	PRON	ADP	ADJ	PUNCT
VERB	0	0.2	0.2	0	0.4	0.2	0
NOUN	0.16	0	0	0	0.16	0.16	0.5
DET	0	1	0	0	0	0	0
PRON	0	0	0	0	0	0	0
ADP	0	0.3	0.6	0	0	0	0
ADJ	0	0	0	0	0	0	1
PUNCT [†]	0.75	0	0.25	0	0	0	0

[†] This row represents the initial probabilities, π of the model.

We calculate the transition probabilities, A from a matrix of transition counts:

	Second tag						
	VERB	NOUN	DET	PRON	ADP	ADJ	PUNCT
VERB	0	0.2	0.2	0	0.4	0.2	0
NOUN	0.16	0	0	0	0.16	0.16	0.5
DET	0	1	0	0	0	0	0
PRON	0	0	0	0	0	0	0
ADP	0	0.3	0.6	0	0	0	0
ADJ	0	0	0	0	0	0	1
PUNCT [†]	0.75	0	0.25	0	0	0	0

[†] This row represents the initial probabilities, π of the model.

Analysed:

Vino/NOUN/VERB a/ADP la/DET/PRON playa/NOUN ./PUNCT
Voy/VERB a/ADP la/DET/PRON casa/NOUN/VERB ./PUNCT
Bebe/VERB vino/NOUN/VERB en/ADP casa/NOUN/VERB ./PUNCT
La/DET/PRON casa/NOUN/VERB es/VERB grande/ADJ ./PUNCT
Es/VERB una/DET/PRON/VERB ciudad/NOUN grande/ADJ ./PUNCT

Tagged:


Vino/VERB a/ADP la/DET playa/NOUN ./PUNCT
Voy/VERB a/ADP la/DET casa/NOUN ./PUNCT
Bebe/VERB vino/NOUN en/ADP casa/NOUN ./PUNCT
La/DET casa/NOUN es/VERB grande/ADJ ./PUNCT
Es/VERB una/DET ciudad/NOUN grande/ADJ ./PUNCT


The probability of seeing an ambiguity class given a tag, B .

	VERB	NOUN	DET	PRON	ADP	ADJ	PUNCT
ADJ	0	0	0	0	0	0	2
DET/PRON	0	0	3	0	0	0	0
DET/PRON/VERB	0	0	1	0	0	0	0
NOUN	0	2	0	0	0	0	0
NOUN/VERB	1	4	0	0	0	0	0
ADP	0	0	0	0	3	0	0
PUNCT	0	0	0	0	0	0	5
VERB	4	0	0	0	0	0	0
Total:	5	6	4	0	3	2	5

The probability of seeing an ambiguity class given a tag, B .

	VERB	NOUN	DET	PRON	ADP	ADJ	PUNCT
ADJ	0	0	0	0	0	1.0	0
DET/PRON	0	0	0.75	0	0	0	0
DET/PRON/VERB	0	0	0.25	0	0	0	0
NOUN	0	0.33	0	0	0	0	0
NOUN/VERB	0.2	0.67	0	0	0	0	0
ADP	0	0	0	0	1.0	0	0
PUNCT	0	0	0	0	0	0	1.0
VERB	0.8	0	0	0	0	0	0





Vino a una casa grande.

→

q_F							
VERB							
NOUN							
DET							
PRON							
ADP							
ADJ							
PUNCT							
	VERB/NOUN	ADP	DET/PRON/VERB	NOUN/VERB	ADJ	PUNCT	
	<i>Vino</i>	<i>a</i>	<i>una</i>	<i>casa</i>	<i>grande</i>	<i>.</i>	

→

q_F							
VERB	0.15, q_0						
NOUN	0.0, q_0						
DET							
PRON							
ADP							
ADJ							
PUNCT							
	VERB/NOUN	ADP	DET/PRON/VERB	NOUN/VERB	ADJ	PUNCT	
	<i>Vino</i>	<i>a</i>	<i>una</i>	<i>casa</i>	<i>grande</i>	<i>.</i>	

- $= P(\text{VERB}, \text{PUNCT}) * P(\text{VERB}, \text{VERB/NOUN}) = 0.75 * 0.2 = 0.15$
- $= P(\text{NOUN}, \text{PUNCT}) * P(\text{NOUN}, \text{VERB/NOUN}) = 0.0 * 0.67 = 0.0$

→

q_F							
VERB	0.15, q_0						
NOUN	0.0, q_0						
DET							
PRON							
ADP		0.06, VERB					
ADJ							
PUNCT							
	VERB/NOUN	ADP	DET/PRON/VERB	NOUN/VERB	ADJ	PUNCT	
	<i>Vino</i>	<i>a</i>	<i>una</i>	<i>casa</i>	<i>grande</i>	<i>.</i>	

- $= P(\text{ADP}, \text{VERB}) * P(\text{ADP}, \text{ADP}) * P(\text{PATH}) = 0.4 * 1.0 * 0.15 = 0.06$
- $= P(\text{ADP}, \text{NOUN}) * P(\text{ADP}, \text{ADP}) * P(\text{PATH}) = 0.16 * 1.0 * 0.0 = 0$

→

q_F							
VERB	0.15, q_0		0.0, ADP				
NOUN	0.0, q_0						
DET			0.009, ADP				
PRON			0.0, ADP				
ADP		0.06, VERB					
ADJ							
PUNCT							
	VERB/NOUN	ADP	DET/PRON/VERB	NOUN/VERB	ADJ	PUNCT	
	<i>Vino</i>	<i>a</i>	<i>una</i>	<i>casa</i>	<i>grande</i>	<i>.</i>	

- $= P(\text{DET}, \text{ADP}) * P(\text{DET}, \text{DET/PRON/VERB}) * P(\text{PATH}) = 0.6 * 0.25 * 0.06 = 0.009$
- $= P(\text{PRON}, \text{ADP}) * P(\text{PRON}, \text{DET/PRON/VERB}) * P(\text{PATH}) = 0.0 * 0.0 * 0.06 = 0.0$
- $= P(\text{VERB}, \text{ADP}) * P(\text{VERB}, \text{DET/PRON/VERB}) * P(\text{PATH}) = 0.0 * 0.0 * 0.06 = 0.0$

→

q_F							
VERB	0.15, q_0		0.0, ADP	0.0, DET*			
NOUN	0.0, q_0			0.006, DET			
DET			0.009, ADP				
PRON			0.0, ADP				
ADP		0.06, VERB					
ADJ							
PUNCT							
	VERB/NOUN	ADP	DET/PRON/VERB	NOUN/VERB	ADJ	PUNCT	
	<i>Vino</i>	<i>a</i>	<i>una</i>	<i>casa</i>	<i>grande</i>	<i>.</i>	

- $= P(\text{NOUN, VERB}) * P(\text{NOUN, NOUN/VERB}) * P(\text{PATH}) = 0.2 * 0.67 * 0.009 = 0.001$
- $= P(\text{VERB, VERB}) * P(\text{VERB, NOUN/VERB}) * P(\text{PATH}) = 0.0 * 0.2 * 0.009 = 0.0$
- $= P(\text{NOUN, DET}) * P(\text{NOUN, NOUN/VERB}) * P(\text{PATH}) = 1.0 * 0.67 * 0.009 = 0.006$
- $= P(\text{VERB, DET}) * P(\text{VERB, NOUN/VERB}) * P(\text{PATH}) = 0.0 * 0.2 * 0.009 = 0.0$
- $= P(\text{NOUN, PRON}) * P(\text{NOUN, NOUN/VERB}) * P(\text{PATH}) = 0.0 * 0.67 * 0.009 = 0.0$
- $= P(\text{VERB, PRON}) * P(\text{VERB, NOUN/VERB}) * P(\text{PATH}) = 0.0 * 0.67 * 0.009 = 0.0$

→

q_F							
VERB	0.15, q_0		0.0, ADP	0.0, DET*			
NOUN	0.0, q_0			0.006, DET			
DET			0.009, ADP				
PRON			0.0, ADP				
ADP		0.06, VERB					
ADJ					0.001, NOUN		
PUNCT							
	VERB/NOUN	ADP	DET/PRON/VERB	NOUN/VERB	ADJ	PUNCT	
	<i>Vino</i>	<i>a</i>	<i>una</i>	<i>casa</i>	<i>grande</i>	<i>.</i>	

- $= P(\text{ADJ}, \text{NOUN}) * P(\text{ADJ}, \text{ADJ}) * P(\text{PATH}) = 0.16 * 1.0 * 0.006 = 0.00096$
- $= P(\text{ADJ}, \text{VERB}) * P(\text{ADJ}, \text{ADJ}) * P(\text{PATH}) = 0.2 * 1.0 * 0.0 = 0.0$

→

q_F							
VERB	0.15, q_0		0.0, ADP	0.0, DET*			
NOUN	0.0, q_0			0.006, DET			
DET			0.009, ADP				
PRON			0.0, ADP				
ADP		0.06, VERB					
ADJ					0.001, NOUN		
PUNCT						0.001, ADJ	
	VERB/NOUN	ADP	DET/PRON/VERB	NOUN/VERB	ADJ	PUNCT	
	<i>Vino</i>	<i>a</i>	<i>una</i>	<i>casa</i>	<i>grande</i>	<i>.</i>	

- $= P(\text{PUNCT}, \text{ADJ}) * P(\text{PUNCT}, \text{PUNCT}) * P(\text{PATH}) = 1.0 * 1.0 * 0.001 = 0.001$

→

q_F							
VERB	0.15, q_0		0.0, ADP	0.0, DET*			
NOUN	0.0, q_0			0.006, DET			
DET			0.009, ADP				
PRON			0.0, ADP				
ADP		0.06, VERB					
ADJ					0.001, NOUN		
PUNCT						0.001, ADJ	
	VERB/NOUN	ADP	DET/PRON/VERB	NOUN/VERB	ADJ	PUNCT	
	<i>Vino</i>	<i>a</i>	<i>una</i>	<i>casa</i>	<i>grande</i>	<i>.</i>	

PUNCT

→

q_F							
VERB	0.15, q_0		0.0, ADP	0.0, DET*			
NOUN	0.0, q_0			0.006, DET			
DET			0.009, ADP				
PRON			0.0, ADP				
ADP		0.06, VERB					
ADJ					0.001, NOUN		
PUNCT						0.001, ADJ	
	VERB/NOUN	ADP	DET/PRON/VERB	NOUN/VERB	ADJ	PUNCT	
	<i>Vino</i>	<i>a</i>	<i>una</i>	<i>casa</i>	<i>grande</i>	.	

ADJ PUNCT

→

q_F							
VERB	0.15, q_0		0.0, ADP	0.0, DET*			
NOUN	0.0, q_0			0.006, DET			
DET			0.009, ADP				
PRON			0.0, ADP				
ADP		0.06, VERB					
ADJ					0.001, NOUN		
PUNCT						0.001, ADJ	
	VERB/NOUN	ADP	DET/PRON/VERB	NOUN/VERB	ADJ	PUNCT	
	<i>Vino</i>	<i>a</i>	<i>una</i>	<i>casa</i>	<i>grande</i>	.	

NOUN ADJ PUNCT

→

q_F							
VERB	0.15, q_0		0.0, ADP	0.0, DET*			
NOUN	0.0, q_0			0.006, DET			
DET			0.009, ADP				
PRON			0.0, ADP				
ADP		0.06, VERB					
ADJ					0.001, NOUN		
PUNCT						0.001, ADJ	
	VERB/NOUN	ADP	DET/PRON/VERB	NOUN/VERB	ADJ	PUNCT	
	<i>Vino</i>	<i>a</i>	<i>una</i>	<i>casa</i>	<i>grande</i>	<i>.</i>	

DET NOUN ADJ PUNCT

→

q_F							
VERB	0.15, q_0		0.0, ADP	0.0, DET*			
NOUN	0.0, q_0			0.006, DET			
DET			0.009, ADP				
PRON			0.0, ADP				
ADP		0.06, VERB					
ADJ					0.001, NOUN		
PUNCT						0.001, ADJ	
	VERB/NOUN	ADP	DET/PRON/VERB	NOUN/VERB	ADJ	PUNCT	
	<i>Vino</i>	<i>a</i>	<i>una</i>	<i>casa</i>	<i>grande</i>	<i>.</i>	

ADP DET NOUN ADJ PUNCT

→

q_F							
VERB	0.15, q_0		0.0, ADP	0.0, DET*			
NOUN	0.0, q_0			0.006, DET			
DET			0.009, ADP				
PRON			0.0, ADP				
ADP		0.06, VERB					
ADJ					0.001, NOUN		
PUNCT						0.001, ADJ	
	VERB/NOUN	ADP	DET/PRON/VERB	NOUN/VERB	ADJ	PUNCT	
	<i>Vino</i>	<i>a</i>	<i>una</i>	<i>casa</i>	<i>grande</i>	.	

VERB ADP DET NOUN ADJ PUNCT

→

q_F							
VERB	0.15, q_0		0.0, ADP	0.0, DET*			
NOUN	0.0, q_0			0.006, DET			
DET			0.009, ADP				
PRON			0.0, ADP				
ADP		0.06, VERB					
ADJ					0.001, NOUN		
PUNCT						0.001, ADJ	
	VERB/NOUN	ADP	DET/PRON/VERB	NOUN/VERB	ADJ	PUNCT	
	<i>Vino</i>	<i>a</i>	<i>una</i>	<i>casa</i>	<i>grande</i>	<i>.</i>	

VERB ADP DET NOUN ADJ PUNCT



- Trigrams
- Backoff
- Unknown words
- Capitalisation

Averaged perceptron


```
1. def train(self, nr_iter, examples):
2.     ''' Update the feature weights according to guesses '''
3.     for i in range(nr_iter):
4.         for features, true_tag in examples:
5.             guess = self.predict(features)
6.             if guess != true_tag:
7.                 for f in features:
8.                     self.weights[f][true_tag] += 1
9.                     self.weights[f][guess] -= 1
10.        random.shuffle(examples)
11.
```

Vino a una casa grande .
 $i - 2$ $i - 1$ i $i + 1$ $i + 2$ $i + 3$

i	Trigram suffix	una
i	Unigram prefix	u
$i - 1$	Tag	ADP
$i - 2$	Tag	VERB
i	Word	una
$i - 1, i$	Tag, Word	ADP + una
$i - 1$	Word	a
$i - 1$	Trigram suffix	a
$i - 2$	Word	Vino
$i + 1$	Word	casa
$i + 1$	Trigram suffix	asa
$i + 2$	Word	grande



```
1. def predict(self, features):
2.     '''Dot-product the features and current weights and return the best class.'''
3.     scores = defaultdict(float)
4.     for feat in features:
5.         if feat not in self.weights:
6.             continue
7.         weights = self.weights[feat]
8.         for clas, weight in weights.items():
9.             scores[clas] += weight
10.    # Do a secondary alphabetic sort, for stability
11.    return max(self.classes, key=lambda clas: (scores[clas], clas))
12.
```


How much data ?





- **Tagger comparison:**
 - Compare three taggers on a language of your choice
- **Constraint grammar:**
 - Select a small text (500 tokens) in a language of your choice
 - Analyse it with a morphological analyser
 - Resolve as much of the ambiguity as you can
- **Perceptron tagger:**
 - Download <https://github.com/ftyers/conllu-perceptron-tagger>
 - Run it on a language from Universal Dependencies
 - Improve it so that you get better performance
 - Add support for morphological features
 - Try tweaking other features