



НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ
УНИВЕРСИТЕТ

Morphological modelling

Francis M. Tyers

ftyers@hse.ru

<https://www.hse.ru/org/persons/209454856>

Национальный исследовательский университет
«Высшая школа экономики» (Москва)

28 октября 2018 г.



В 1942—1945 годах профессором [Г. С. Петровым](#) и сотрудниками была разработана серия клеев БФ^[1]. Советский учёный-химик Петров знаменит также «контактом Петрова» и работами в области химии и технологии [карболита](#) ([бакелита](#), фенолформальдегидных пластмасс)^[2].



В 1942–1945 годах профессором [[Петров, Григорий Семёнович|Г. С. Петровым]] и сотрудниками была разработана серия клеев БФ<ref><http://chem21.info/page/034120176225149200221127252239157188201019105199/> Справочник по пластическим массам Том 2 (1969) стр.149.]</ref>. Советский учёный-химик Петров знаменит также «контактом Петрова» и работами в области химии и технологии [[карболит]]а ([[бакелит]]а, фенолформальдегидных пластмасс)<ref><http://www.planet-of-people.org/htmls/rus/nadezhdin/plastmassa.htm> Надеждин Н. Я. История науки и техники. Пластмасса<!-- Заголовок добавлен ботом -->{{Недоступная ссылка|date=Июль 2018 |bot=InternetArchiveBot }}{{битая ссылка}}</ref>.



В 1942–1945 годах профессором Г. С. Петровым и сотрудниками была разработана серия клеев БФ. Советский учёный-химик Петров знаменит также «контактом Петрова» и работами в области химии и технологии карболита (бакелита, фенолформальдегидных пластмасс).



В 1942 – 1945 годах профессором Г. С. Петровым и сотрудниками была разработана серия клеев БФ . Советский учёный-химик Петров знаменит также « контактом Петрова » и работами в области химии и технологии карболита (бакелита , фенолформальдегидных пластмасс) .

В 1942—1945 годах профессором [Г. С. Петровым](#) и сотрудниками была разработана серия клеев БФ^[1]. Советский учёный-химик Петров знаменит также «контактом Петрова» и работами в области химии и технологии [карболита](#) ([бакелита](#), фенолформальдегидных пластмасс)^[2].



В 1942–1945 годах профессором [[Петров, Григорий Семёнович|Г. С. Петровым]] и сотрудниками была разработана серия клеев БФ<ref><http://chem21.info/page/034120176225149200221127252239157188201019105199/> Справочник по пластическим массам Том 2 (1969) стр.149.</ref>. Советский учёный-химик Петров знаменит также «контактом Петрова» и работами в области химии и технологии [[карболит]]а ([[бакелит]]а, фенолформальдегидных пластмасс)<ref><http://www.planet-of-people.org/htmls/rus/nadezhdin/plastmassa.htm> Надеждин Н. Я. История науки и техники. Пластмасса<!-- Заголовок добавлен ботом -->{{Недоступная ссылка|date=Июль 2018 |bot=InternetArchiveBot }}{{битая ссылка}}</ref>.



В 1942–1945 годах профессором Г. С. Петровым и сотрудниками была разработана серия клеев БФ. Советский учёный-химик Петров знаменит также «контактом Петрова» и работами в области химии и технологии карболита (бакелита, фенолформальдегидных пластмасс).



В 1942 – 1945 годах профессором Г. С. Петровым и сотрудниками была разработана серия клеев БФ . Советский учёный-химик Петров знаменит также « контактом Петрова » и работами в области химии и технологии карболита (бакелита , фенолформальдегидных пластмасс) .

- Morphology: What is it? Why should we care?
- Modelling morphology: With finite-state machines
-

Morphology

Morphology is:

« the branch of linguistics that studies patterns of word formation within and across languages, and attempts to formulate rules that model the knowledge of the speakers of those languages. »

This is a big field, here we are interested in practical models.

English or Chinese:

- A full form list is a possibility
- Few or no inflectional forms
 - e.g. 5 forms per English verb {see, sees, saw, seen, seeing}

Other languages:

- Difficult or impossible to enumerate all forms
- Very productive inflection and derivation
 - Russian verbs: over 150 forms (maximally)
 - Turkish verbs: thousands of forms



A morphological lexicon consists of entries:

- Lemma: The citation form of a word (cf. headword)
- Stem: The part of a word affixes attach to
- Paradigm: A description of how the word inflects:

Add additional meaning or change the meaning of a lexical stem:

- **Suffixes:** *hus* 'house' — *huset* 'the house'
- **Prefixes:** *kjent* 'known' — *ukjent* 'unknown'
- **Infixes:** *ktieb* 'book' — *kotba* 'books'
- **Circumfixes:** *nagy* 'big' — *legnagyobb* 'biggest'

- **Inflection:** Inflectional morphemes carry grammatical information, such as number, case, tense, etc., but do not change the word category
- **Derivation:** Derivational morphemes change the basic semantic meaning of a word, and can also change word category.
- **Compounding:** A process where two or more words are joined together to form one, typically of the same category or supertype.
- **Clitics:** Syntactically independent word that functions phonologically as an affix of another word.
- **Incorporation:** Where a nominal (e.g. direct object) or adverbial is included into a verb form.

Examples of inflection categories:

- **Case:**

дом-у 'house-LOC', *ev-de* 'house-LOC', *talo-ssa* 'house-INE'

- **Possession:**

ev-im 'house-1SG', *talo-ni* 'house-1SG'

- **Number:**

дом-а 'house-PL', *ev-ler* 'house-PL', *talo-t* 'house-PL'

- **Tense, aspect, mood:**

говори-ла 'say-PAST.F', *söyle-di* 'say-PAST', *puhu-i* 'say-PAST'

- **Comparison:**

больш-е 'big-COMP', *нысăк-рах* 'big-COMP', *iso-mpi* 'big-COMP'

In general: Change in meaning is regular.

Examples of derivational affixes:

- Actor: *diş-çi* /tooth-er/ 'dentist'
- State: *boş-luk* 'emptiness', *nycm-oma* 'emptiness'
- Diminutive: *dog-gie*, *kedi-cik* /cat-DIM/ 'kitten'

Can often be stacked:

- *temizlikçi* /temiz-lik-çi/ clean-ness-er = cleaner
- *поверхностный* /по-верх-ность-ный/ on-surface-ness-ly = superficial

Change in meaning may be irregular, compare:

- *cooker* /cook-er/ 'machine that cooks'
- *cleaner* /clean-er/ 'person who cleans'
- *looker* /look-er/ 'person that looks good'

May be limited to particular stems.

New words are formed from morphologically/syntactically independent words:

- This may be indicated in the writing system or not.
 - infrastruktuurontwikkelingsplan, or
 - infrastructure development plan
- tri-noun compounds, but different orthographical treatment

Note: a given compound word may be split different ways, or a given word may appear as a compound, but not be one:

- Freitag = Friday (not “Frei” + “tag” = free day)
- kulturforskeren = the ethnographer, and not
 - kultur+forskeren = “culture researcher”
 - kultur+forske+ren = “culture research clean”

Clitics are syntactically separate words that are phonologically conditioned by another unit (word, phrase).

- **Pronominal:**

- Spanish: *me lo das* me it you.give 'You give it to me'
- Spanish: *dámelo!* give-me-it 'Give it to me!'

- **Verb forms:**

- Serbo-Croatian: *govorit ću* vs. *govoriću* 'I will speak'
- English: *I'm* 'I am', *gonna* 'going to'

- **Other:**

- Question words (e.g. Finnish *onko?* is-QST? 'Is there?')
- Tense markers (e.g. Kurdish *-ê*)

Should these be tokenised prior to analysis?

Гақорапэнратлэн Сыкwaңақай рэмкык

"Cikwaṇaqaj chased after the reindeer in the other encampment."

га-қора-пэнр-ат-лэн	Сыкwaңақай	рэмк-ык
PERF-reindeer-chase-s3SG	Cikwaṇaqaj	folk-LOC

- Syntactically determined (not lexically!)
- Can be valency changing, e.g.
 - DOBJ + V.TR → V.INTR
- ...



- Analytic—Synthetic:
 - Morphemes per word
- Agglutinative—Fusional:
 - Meanings per morpheme

Modelling

Analysis:

студента \rightarrow {студент<n><m><aa><sg><gen>,
студент<n><m><aa><sg><acc> }

Generation:

студент<n><m><aa><sg><gen> \rightarrow студента

How morphemes can be combined:

- студентом, играющийся, played, evlerde
- *омстудент, *ющийсяигра, *edplay, *deevler

The changes that happen when morphemes are combined:

- работа + ы → работы
- fox + s → foxes
- огонёк + и → огоньки

Let's take the Turkish words *ev* 'house', *kız* 'girl':

	Singular	Plural
Nominative	ev, kız	ev-ler, kız-lar
Accusative	ev-i, kız-ı	ev-ler-i, kız-lar-ı
Genitive	ev-in, kız-ın	ev-ler-in, kız-lar-ın
Dative	ev-e, kız-a	ev-ler-e, kız-lar-a
Locative	ev-de, kız-da	ev-ler-de, kız-lar-da
Ablative	ev-den, kız-dan	ev-ler-den, kız-lar-dan

Suffixes are different according to **front** and **back** vowels.

We can represent these as a finite-state automaton:



Where the labels would mean:

- **front-stem**: the front stems (e.g. *ev*)
- **back-stem**: the back stems (e.g. *kız*)
- **front-suffix**: the front suffixes (e.g. *-de*)
- **back-suffix**: the back suffixes (e.g. *-da*)



- Q = Set of N states
- Σ = Input alphabet
- Δ = Output alphabet
- $q_0 \in Q$ = A single start state
- $F \subseteq Q$ = A set of final states

Let's add another complication:

	Singular	Plural
Nominative	ev, kız, baş	evler, kızlar, başlar
Accusative	evi, kızı, başı	evleri, kızları, başları
Genitive	evin, kızın, başın	evlerin, kızların, başların
Dative	eve, kıza, başa	evlere, kızlara, başlara
Locative	evde, kızda, başta	evlerde, kızlarda, başlarda
Ablative	evden, kızdan, baştan	evlerden, kızlardan, başlardan


Some suffix consonants can change *başta* not **başda*.

b	a	ξ	>	{D}	{A}
b	a	ξ	0	t	a

"Vowel harmony for archiphoneme {A}"

$\% \{A\} : a \leq \text{Back} [\text{Cns} : | : \text{Back} | \% > :]^* _ ;$

- **Symbol pair:** The symbol pair to constraint
- **Rule operator:** The type of constraint
- **Rule context:** The context where the rule should apply
- **Rule centre:** Where the symbol pair is found in the context




	<i>Positive Reading</i>	<i>Negative Reading</i>
<code>a:b <=> l _ r ;</code>	<ol style="list-style-type: none"> 1. If the symbol pair a:b appears, it must be in the context l _ r. 2. If lexical a appears in the context l _ r, then it must be realized on the surface as b. 	<ol style="list-style-type: none"> 1. If the symbol pair a:b appears outside the context l _ r, FAIL. 2. If lexical a appears in the context l _ r and is realized as anything other than b, FAIL.
<code>a:b => l _ r ;</code>	If the symbol pair a:b appears, it must be in the context l _ r.	If the symbol pair a:b appears outside the context l _ r, FAIL.
<code>a:b <= l _ r ;</code>	If lexical a appears in the context l _ r, it must be realized on the surface as b.	If lexical a appears in the context l _ r and is realized as anything other than b, FAIL.
<code>a:b /<= l _ r ;</code>	Lexical a is never realized as b in the context l _ r.	If lexical a is realized as b in the context l _ r, FAIL.

Table 1.1: **twolc** Rule Operator Semantics

- Rules are applied in parallel
- Every pair must be accepted by all rules

Development



Take frequency into account, of:

- Stems
- Morphemes
- Phonological rules



- Templatic morphology:
- Machine learning approaches:
- Rewrite rules:

Go through the following practical:

https://ftyers.github.io/2017-КЛ_МКЛ/hfst.html

This will take you through all of the main steps to build a transducer.